Text-to-SQL en español

Fine-tuning de Qwen2.5-Coder-1.5B-Instruct con LoRA para MySQL 8.4

Adrián González · José Ordóñez

Deep Learning 2026 — Universidad del Valle de Guatemala — Proyecto 3

Qué hicimos

- Objetivo: dado el esquema (SHOW CREATE TABLE con COMMENT) y una pregunta en español, generar una sola consulta SELECT/WITH correcta para MySQL 8.4 (ONLY_FULL_GROUP_BY).
- Modelo: Qwen/Qwen2.5-Coder-1.5B-Instruct + adapter LoRA propio. Sin APIs externas.
- Medida: exactitud por ejecución ponderada (fácil 1, media 2, difícil 3), igual que la evaluación oculta.
- Inferencia determinista (beam search sin muestreo, semilla 2026) y filtro que bloquea cualquier consulta que modifique la base.
- Opcional en evaluación: ejecutar() para elegir entre candidatos y corregir con el error de MySQL (máx. 3 llamadas).

Dataset de entrenamiento

- (pendiente: correr notebooks/01_datos.ipynb)

Validación propia (partición por esquema)

- 2 esquemas que NO aparecen en entrenamiento: biblioteca (6 tablas, nombres en español) y gym_mgmt (7 tablas, nombres abreviados en inglés).
- 40 preguntas escritas por nosotros: 13 fáciles, 14 medias, 13 difíciles.
- Ninguna tabla de validación comparte nombre con tablas de entrenamiento (se verifica en el notebook de datos).
- Mismo criterio que el docente: orden solo si se pide, redondeo a 2 decimales, columnas extra no penalizan.

Prompt y formato del esquema

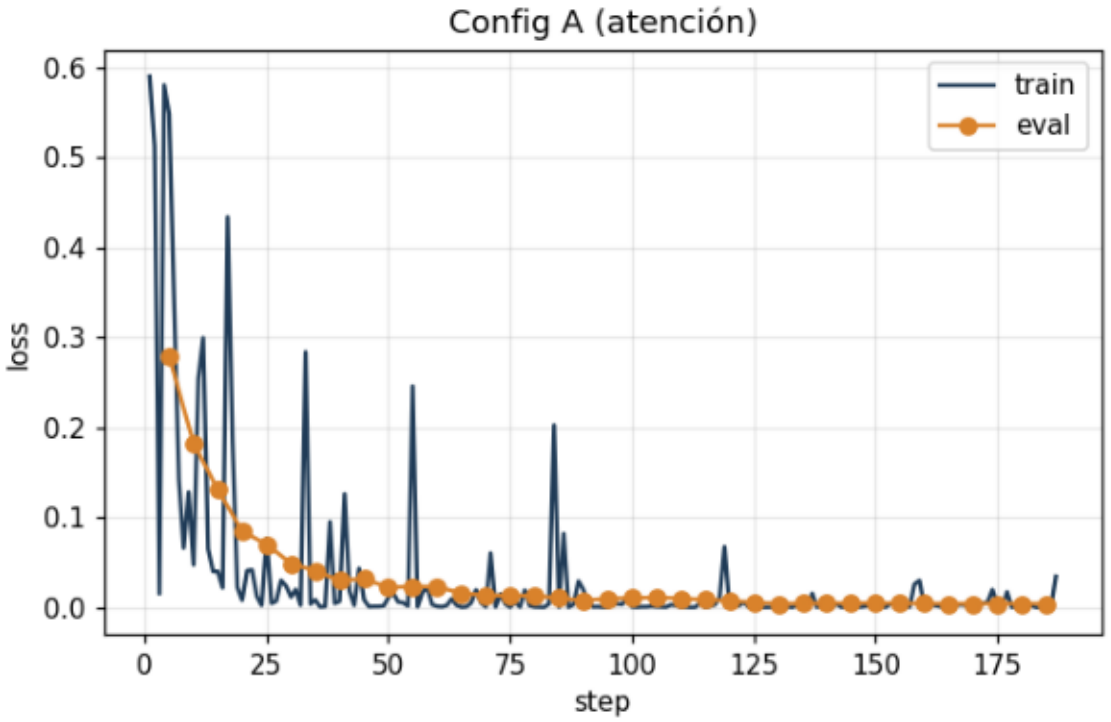
- System: rol de experto en MySQL 8.4 + reglas (solo lectura, ONLY_FULL_GROUP_BY, sin explicaciones).
- User: ### Esquema (compactado) → ### Pregunta → ### SQL. El mismo prompt con y sin adapter.
- Compactación: se quitan índices KEY, ENGINE/CHARSET/AUTO_INCREMENT y NOT NULL; se conservan tipos, COMMENT, PK y FK. Ahorra ~35% de tokens.
- Post-proceso: se extrae la primera sentencia SELECT/WITH y se rechaza todo lo que pueda modificar la base.

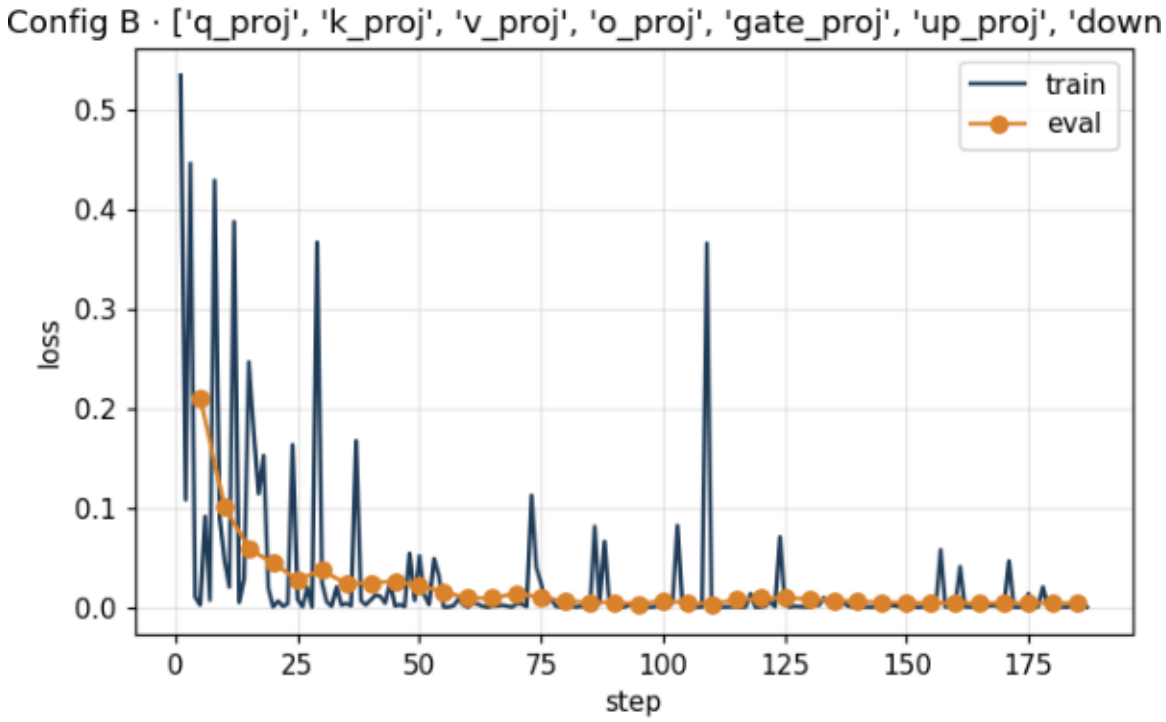
Dos configuraciones de LoRA (un solo factor)

	Config A	Config B
target_modules	q,k,v,o	q,k,v,o + gate,up,down
rank / alpha	16 / 32	16 / 32
parámetros entrenables	4,358,144	18,464,768
tiempo (min, T4)	42.5	57.2
eval loss final	0.004	0.004
EX validación (greedy)	0.675	0.562

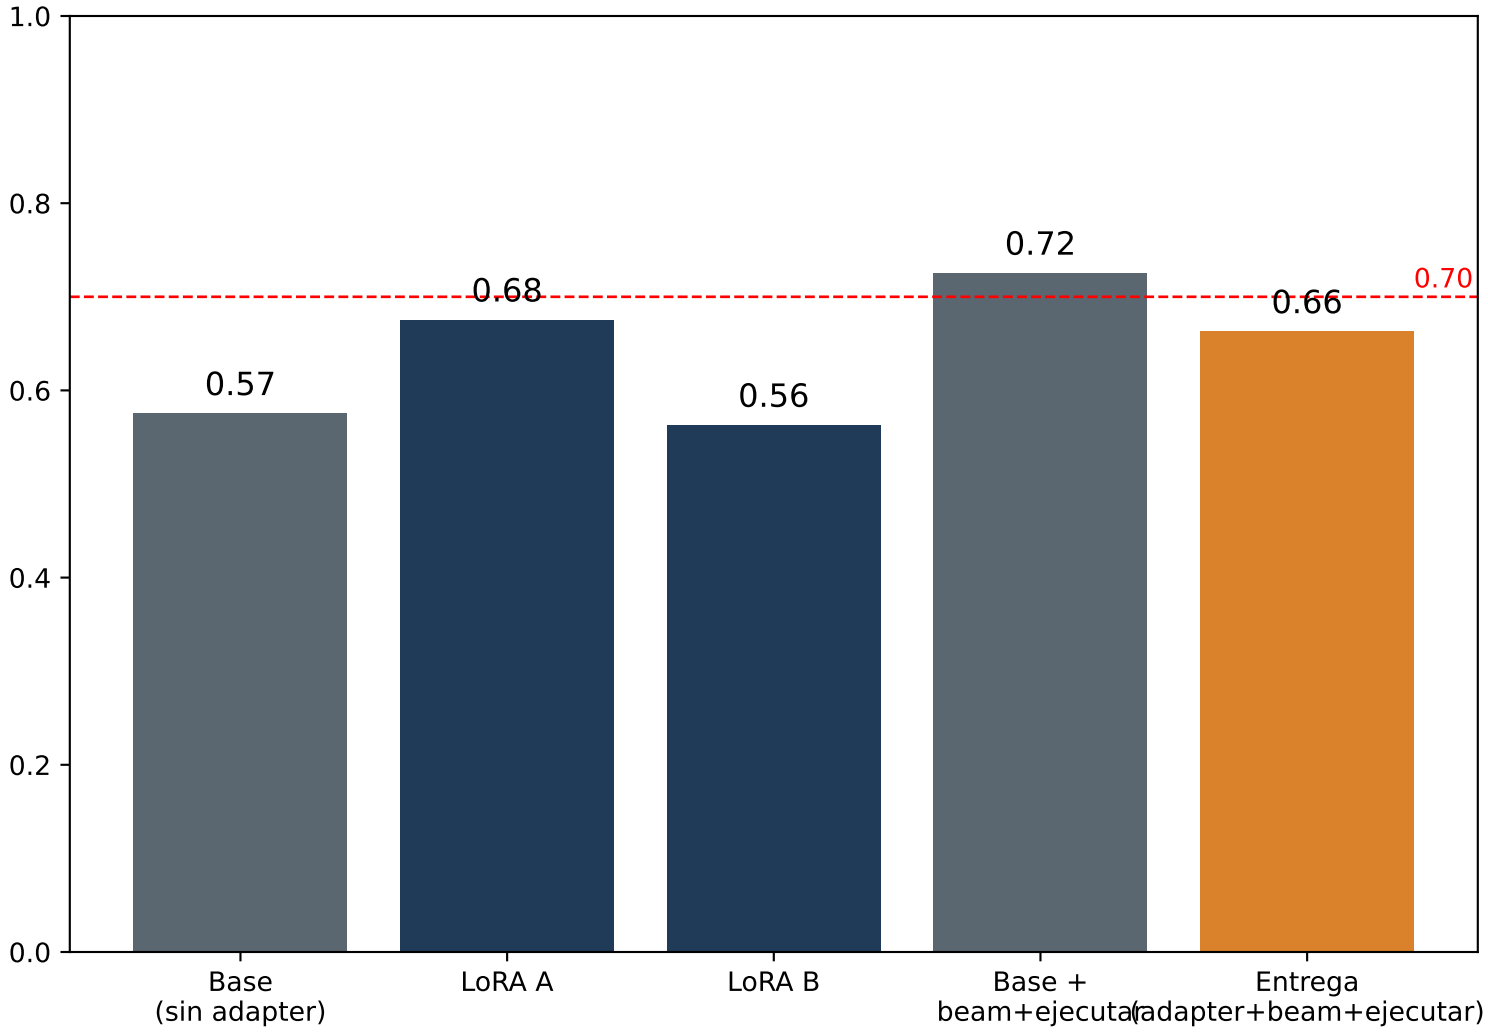
- Hipótesis (escrita antes de entrenar): agregar el MLP multiplica por ~4 los parámetros entrenables y debería mejorar sobre todo las preguntas difíciles (subconsultas, ventanas), a cambio de más tiempo y más riesgo de sobreajuste a las plantillas.
- Fijo en ambas: 1 época (3,200 ejemplos), lr 2e-4 coseno, batch efectivo 16, dropout 0.05, máx. 2048 tokens, semilla 2026.

Curvas de loss



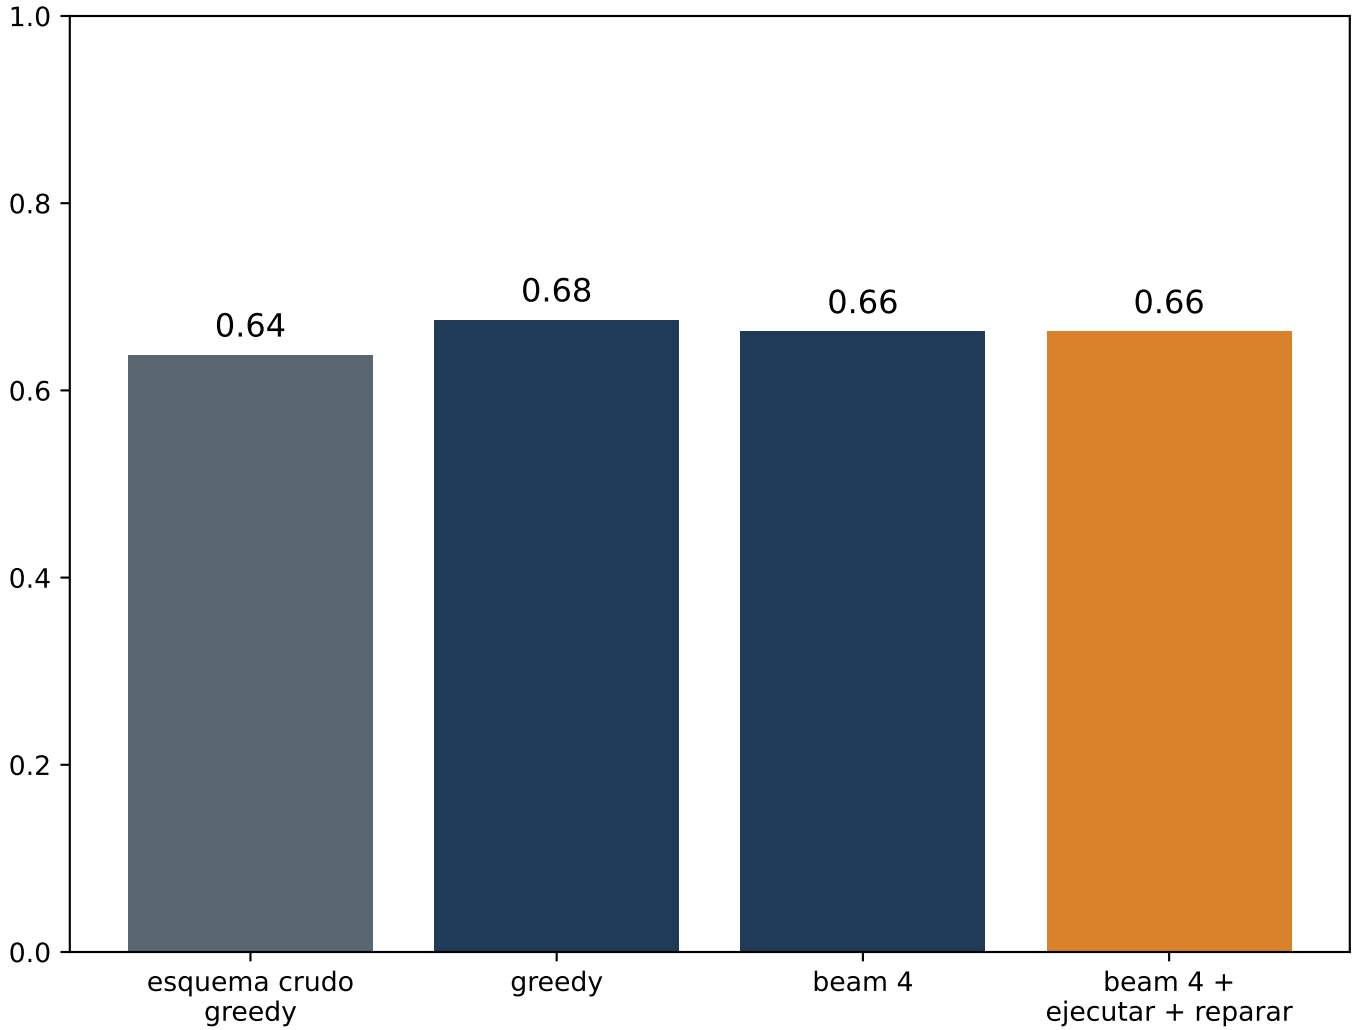


Resultados en validación propia (EX ponderada)



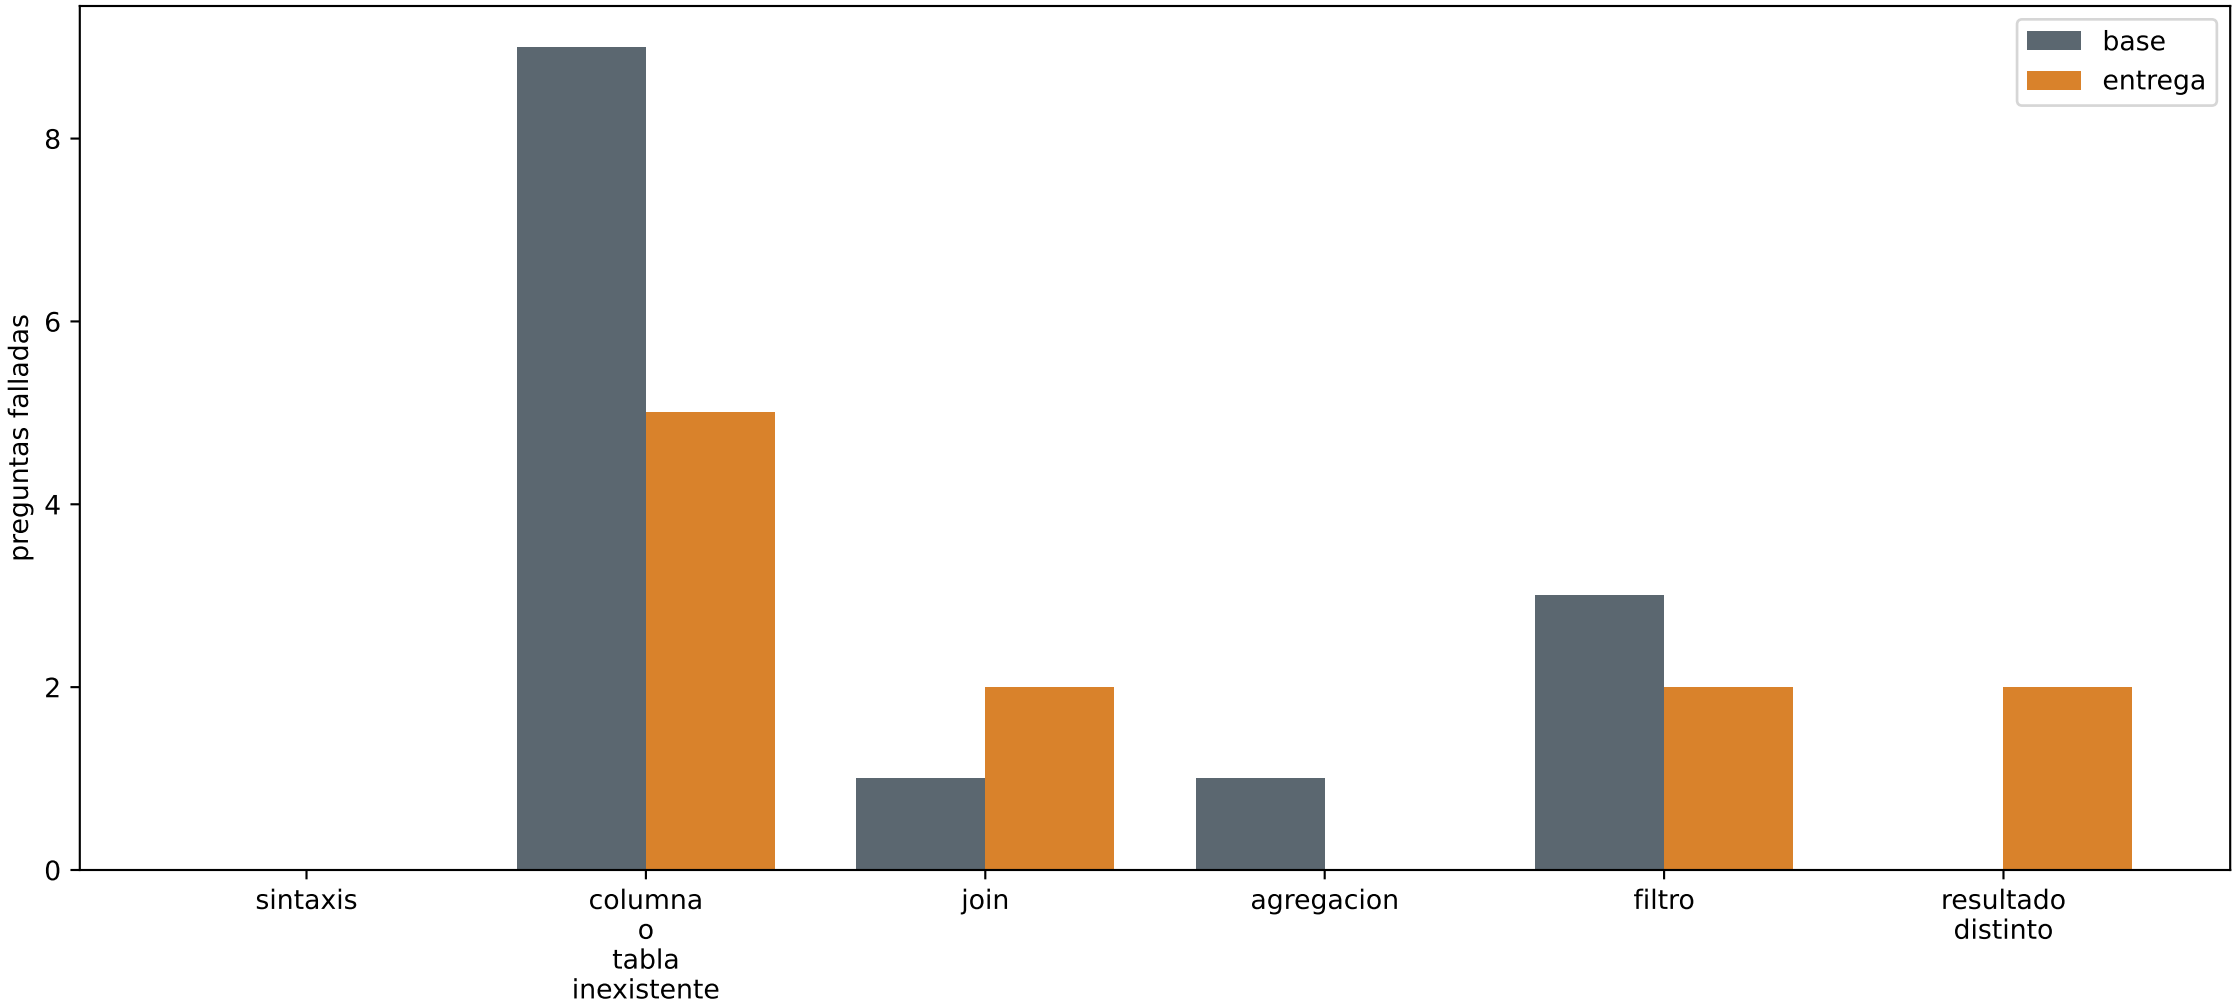
- Base (sin adapter): F 0.77 / M 0.86 / D 0.31
- LoRA A: F 0.85 / M 0.57 / D 0.69
- LoRA B: F 0.85 / M 0.57 / D 0.46
- Base + beam+ejecutar: F 0.85 / M 0.93 / D 0.54
- Entrega (adapter+beam+ejecutar): F 0.92 / M 0.71 / D 0.54
- Mejora del adapter (mismo pipeline): -0.062

Experimento de inferencia: usar ejecutar()



- Hipótesis: la mayoría de fallos de un modelo pequeño son nombres de columna/tabla inventados o GROUP BY incompletos, que MySQL detecta. Con el error en el prompt el modelo puede corregir.
- Estrategia (≤3 llamadas): ejecutar el mejor candidato; si falla, reparar con el error; si corre sin filas, probar el siguiente candidato del beam.
- También probamos pasar el esquema crudo vs compactado.

Análisis de errores por categoría



Predicción de EX en la evaluación oculta

- EX ponderada en validación propia (pipeline de entrega): 0.662; intervalo bootstrap 90%: [0.53, 0.80].
- Predicción: EX ≈ 0.62 (rango 0.43–0.82).
- EX ponderada en la validación propia (pipeline de entrega): 0.662.
- Fácil acierta 0.92; los pesos 1/2/3 del docente premian de forma parecida.
- El 45% de los fallos en la validación fue sintaxis o columna/tabla inexistente, que es justo lo que el paso de ejecutar + reparar suele poder corregir.
- Bootstrap de 2000 re-muestreos sobre las 40 preguntas (semilla 2026): IC 90% = [0.53, 0.80].
- Ajuste final por estilo: −0.05 (preguntas ocultas más variadas y hasta 10 tablas por esquema) más +0.02 por la proporción reparable de errores (45%) en la validación.

Conclusiones y siguiente paso

- El mayor aporte viene de que el modelo aprende el formato (solo SQL, MySQL, alias, ONLY_FULL_GROUP_BY) y a leer los COMMENT para mapear nombres abreviados.
- Ejecutar y reparar ataca los errores baratos (columnas inexistentes, sintaxis); los errores de lógica (filtro o resultado distinto) siguen siendo el límite.
- Riesgo principal: nuestras preguntas salen de plantillas; el estilo libre del docente puede bajar el resultado.
- Para el Proyecto Final: conservamos adapter, prompt, dataset y evaluador; siguiente paso es sumar preguntas de Spider/BIRD traducidas y más esquemas con 8–10 tablas.